

R project: Опускание аргументов в языке На'ви и их экспликация в английском переводе

Артамонова Ксения

2026

Введение

Цель данного проекта заключается в том, чтобы провести количественный и качественный анализ частоты опущения аргументов глагольных предикатов в языке На'ви по сравнению с их английскими переводами.

Предмет исследования: закономерности распределения аргументов в зависимости от семантической роли (агенса/пациенса) и языковой системы.

Материал исследования: параллельный корпус текстов на языке на'ви и их переводов на английский язык

Гипотеза 1: Аргументы глагола опускаются в языке на'ви чаще, чем в английском переводе.

Гипотеза 2: Частота опущения зависит от семантической роли аргумента: пациент опускается чаще агенса.

Небольшая лингвистическая справка

Семантическая роль - разновидность типовых отношений участника ситуации, обозначаемой предикатом (обычно глаголом), к данной ситуации.

Агенса - одушевлённый инициатор действия, контролирующий его.

Пациент (тема) - участник, больше других вовлечённый в действие и претерпевающий в ходе него наиболее существенные изменения.

Данные

Данные представляют собой параллельный корпус предложений на языке На'ви и их официальных английских переводов из фильмов франшизы «Аватар» Джеймса Кэмерона и связанных материалов (официальные субтитры, материалы выступлений Пола Фроммера и его сайт).

Разметка представлена следующим образом: - Единица анализа: один аргумент одного предиката. - Для каждого аргумента фиксируется: - `navi_expressed` : выражен ли аргумент в на'ви (1 = да, 0 = нет) - `en_expressed` : выражен ли аргумент в английском (1 = да, 0 = нет) - `role` : семантическая роль (`agent` / `patient`) - `target_verb` : целевой глагол

Datасet(https://github.com/blankqspace/data_analysis_R_homeworks/blob/main/project/navi-eng-analysis.csv (https://github.com/blankqspace/data_analysis_R_homeworks/blob/main/project/navi-eng-analysis.csv))

```
navi_data <- read.csv("navi-eng-analysis.csv")
str(navi_data)
```

```
## 'data.frame': 101 obs. of 7 variables:
## $ id : int 1 2 3 4 5 6 7 8 9 10 ...
## $ navi : chr "Aylì'u ngian nì'it skepek lu." "Zìsìt amrr ftolia ohe, slä zene f
ko nivume nìtxan." "Zìsìt amrr ftolia ohe, slä zene fko nivume nìtxan." "Zìsìt amrr ftolia oh
e, slä zene fko nivume nìtxan." ...
## $ en : chr "You still sound a bit too formal, though." "I studied for five ye
ars but there is much to learn." "I studied for five years but there is much to learn." "I st
udied for five years but there is much to learn." ...
## $ target_verb : chr "skepek lu" "ftolia" "nivume" "nivume" ...
## $ role : chr "agent" "agent" "agent" "patient" ...
## $ navi_expressed: int 1 1 1 0 1 1 1 1 1 1 ...
## $ en_expressed : int 1 1 0 1 1 1 1 1 1 1 ...
```

```
head(navi_data)
```

```
## id navi
## 1 1 Aylì'u ngian nì'it skepek lu.
## 2 2 Zìsìt amrr ftolia ohe, slä zene fko nivume nìtxan.
## 3 3 Zìsìt amrr ftolia ohe, slä zene fko nivume nìtxan.
## 4 4 Zìsìt amrr ftolia ohe, slä zene fko nivume nìtxan.
## 5 5 Hu nawma sa'nok tivul ngeyä tirea.
## 6 6 Ma sempul, oel ngati kameie.
## en target_verb role
## 1 You still sound a bit too formal, though. skepek lu agent
## 2 I studied for five years but there is much to learn. ftolia agent
## 3 I studied for five years but there is much to learn. nivume agent
## 4 I studied for five years but there is much to learn. nivume patient
## 5 May your spirit run with the Great Mother. tivul agent
## 6 Father, I see you. kameie agent
## navi_expressed en_expressed
## 1 1 1
## 2 1 1
## 3 1 0
## 4 0 1
## 5 1 1
## 6 1 1
```

Описательная статистика распределений в данных и визуализации

Для начала давайте изучим данные и посмотрим общую статистику по количеству выраженных/ невыраженных аргументов.

Для этого воспользуемся функцией **summarise** из пакета **dplyr** и потом визуализируем результаты с помощью **ggplot**. Мы использовали её, чтобы получить общие суммы (sum) и средние значения (mean) по всем столбцам.

Примечание: Почему 1 - mean(...)?

Поскольку наши данные закодированы как 0 (не выражен) и 1 (выражен), среднее значение (mean) автоматически показывает долю единиц (выраженных аргументов). Чтобы получить долю опущений (нулей), мы вычитаем среднее из единицы.

В датасете 101 сэмпл (аргумент), в языке на'ви выражено 88 аргументов, что составляет долю опущений (omission rate) примерно 13%, в английском переводе выражено 99 аргументов, с долей опущений всего около 2%. Уже на этом этапе видно существенное различие: в На'ви аргументы опускаются существенно чаще, чем в английском.

Столбчатая диаграмма ниже наглядно демонстрирует это распределение: светло-зеленый сегмент («Выражен») занимает подавляющую часть пространства, тогда как коралловый сегмент («Не выражен») представлен лишь небольшой долей.

```
library(ggplot2)
library(dplyr)
```

```
##
## Присоединяю пакет: 'dplyr'
```

```
## Следующие объекты скрыты от 'package:stats':
##
## filter, lag
```

```
## Следующие объекты скрыты от 'package:base':
##
## intersect, setdiff, setequal, union
```


```
overall_summary <- navi_data %>%
  summarise(
    total_args = n(),
    navi_expressed_sum = sum(navi_expressed),
    en_expressed_sum = sum(en_expressed),
    navi_omission_rate = 1 - mean(navi_expressed),
    en_omission_rate = 1 - mean(en_expressed)
  )

print(overall_summary)
```

```
## total_args navi_expressed_sum en_expressed_sum navi_omission_rate
## 1          101                88                99          0.1287129
## en_omission_rate
## 1          0.01980198
```

```
ggplot(navi_data, aes(x = "", fill = factor(navi_expressed))) +
  geom_bar(width = 1) +
  coord_flip() +
  scale_fill_manual(
    values = c("0" = "#F9866F", "1" = "#B3E0A6"),
    labels = c("Не выражен (0)", "Выражен (1)"),
    name = "Статус аргумента"
  ) +
  labs(
    title = "Распределение аргументов в На'ви",
    x = "",
    y = "Количество"
  ) +
  theme_light(base_size = 14) +
  theme(
    legend.position = "bottom",
    plot.title = element_text(hjust = 0.5, face = "bold")
  ) +
  geom_text(
    stat = "count",
    aes(label = paste0(round(after_stat(count) / sum(after_stat(count)) * 100, 1), "%")),
    position = position_stack(vjust = 0.5),
    size = 5,
    fontface = "bold",
    color = "black"
  )
)
```

Распределение аргументов в На'ви



Статус аргумента ■ Не выражен (0) ■ Выражен (1)

Далее сравним частоты опущения по каждому языку. Для этого построим сравнительный график с помощью **ggplot**, но сначала нужно подготовить данные, тк оригинальные столбцы сравнивать не

удобно. Мы воспользовались функцией **pivot_longer()** из пакета **tidyr** и объединили столбцы **navi_expressed** и **en_expressed** в один общий столбец значений (**expressed**), потом создали новый столбец-метку (**language**), указывающий, откуда взялось значение. Также поменяли технические названия на более понятные, мы использовали **mutate**, чтобы заменить их на понятные человеку метки **Na'vi** и **English**.

Кроме этого, вместо того чтобы просто суммировать количества, мы используем функцию **stat_summary(fun = "mean", ...)** для вычисления среднего значения переменной **expressed** (где 1 = выражен, 0 = опущен). В контексте бинарных данных среднее значение математически эквивалентно доле единиц (проценту выраженных аргументов). Это позволяет сразу видеть относительную частоту, а не абсолютные числа, и это корректнее для сравнения.

Высота столбца **Na'vi** соответствует примерно 87% (доля выраженных аргументов), что означает около 13% опущений. Высота столбца **English** приближается к 98-100%, что свидетельствует о практически полном отсутствии опущений в английском переводе.


Это визуальное различие поддерживает нашу первую гипотезу: аргументы глагола в языке на'ви опускаются значительно чаще, чем в английском языке, где синтаксические правила требуют обязательного наличия подлежащего и дополнения.

```
library(tidyr)

lang_comparison <- navi_data %>%
  pivot_longer(
    cols = c(navi_expressed, en_expressed),
    names_to = "language",
    values_to = "expressed"
  ) %>%
  mutate(
    language = ifelse(language == "navi_expressed", "Na'vi", "English"),
    language = factor(language, levels = c("Na'vi", "English"))
  )

ggplot(lang_comparison, aes(x = language, y = expressed, fill = language)) +
  stat_summary(fun = "mean", geom = "bar", width = 0.6, alpha = 0.8) +
  stat_summary(
    fun = "mean",
    geom = "text",
    aes(label = paste0(round(after_stat(y) * 100, 1), "%")),
    vjust = -0.5,
    size = 5,
    fontface = "bold",
    color = "black"
  ) +
  scale_fill_manual(
    values = c("Na'vi" = "#87B6D9", "English" = "#2A5783")
  ) +
  labs(
    title = "Сравнение частоты выражения аргументов по языкам",
    x = "Язык",
    y = "Доля выраженных аргументов (0-1)"
  ) +
  scale_y_continuous(
    labels = scales::percent,
    limits = c(0, 1.15)
  ) +
  theme_light(base_size = 14) +
  theme(
    legend.position = "top",
    plot.title = element_text(hjust = 0.5, face = "bold")
  )
```

Сравнение частоты выражения аргументов по языкам



Далее обратимся ко второй гипотезе. Для этого сгруппируем данные по ролям с помощью `group_by()`, а потом посчитаем статистику внутри групп (`summarise()`) и визуализируем.

Результаты визуализации показывают интересную динамику. Как видно из графика, доля опущений для агентов выше чем для пациенсов, что противоречит нашей гипотезе о том, что пациенсы опускаются чаще агентов.

Столбец `agent` имеет высоту примерно 0.17 (17% опущений), а `patient` значительно ниже — около 0.06 (6% опущений).


Это означает, что в нашем корпусе данных агенты (подлежащие) опускаются почти в 3 раза чаще, чем пациенсы (дополнения).

Мы ожидали обратного, предполагая, что объекты действия будут опускаться чаще, но данные свидетельствуют о том, что в на'ви именно подлежащее является более «избыточным» элементом, который можно опустить, если оно понятно из контекста или маркировано через глагол.

```
role_summary <- navi_data %>%
  group_by(role) %>%
  summarise(
    total = n(),
    navi_expressed_mean = mean(navi_expressed),
    en_expressed_mean = mean(en_expressed),
    navi_omission = 1 - navi_expressed_mean,
    en_omission = 1 - en_expressed_mean
  )
print(role_summary)
```

```
## # A tibble: 2 × 6
##   role   total navi_expressed_mean en_expressed_mean navi_omission en_omission
##   <chr>   <int>           <dbl>           <dbl>           <dbl>       <dbl>
## 1 agent     66           0.833           0.970           0.167       0.0303
## 2 patient   35           0.943           1           0.0571       0
```

```
ggplot(role_summary, aes(x = role, y = navi_omission, fill = role)) +
  geom_col() +
  geom_text(
    aes(label = paste0(round(navi_omission * 100, 1), "%")),
    vjust = -0.5,
    size = 5,
    fontface = "bold",
    color = "black"
  ) +
  scale_fill_manual(
    values = c("agent" = "#B0779E", "patient" = "#B99C33"),
  ) +
  labs(title = "Частота опущения аргументов в на'ви по семантическим ролям",
       x = "Роль", y = "Доля опущений") +
  theme_light(base_size = 14) +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```



Таким образом, описательная статистика и визуализация показали, что первая гипотеза подтверждается (на'ви опускает аргументы чаще английского), а вторая требует пересмотра (агенты опускаются чаще пациентов). Далее мы перейдем к статистическому тестированию, чтобы проверить значимость найденных различий.

Статистическое тестирование гипотез

Для первой гипотезы мы возьмём тест Макнемара, тк данные в проекте - парные выборки. Каждый аргумент в датасете имеет два значения: одно для языка на'ви (`navi_expressed`) и соответствующее ему значение для английского перевода (`en_expressed`). Мы сравниваем не две независимые группы, а один и тот же лингвистический материал в двух разных языковых системах. Стандартные тесты, такие как хи-квадрат Пирсона, предполагают независимость выборок, что нарушило бы условия анализа и могло показать неточные результаты. Тест Макнемара специально разработан для таблиц сопряженности 2 на 2 с парными данными и оценивает значимость изменений в дихотомических переменных.

Для второй же гипотезы нам необходимо сравнить долю опущений двух независимых групп (агентов и пациентов) внутри языка На'ви, для этого подойдет критерий хи-квадрат, однако необходима большая выборка данных, которой мы не располагаем, поэтому он нам не подойдет. Как альтернативу, мы возьмем тест Фишера, поскольку он не зависит от объема данных.

```
table_lang <- table(navi_data$navi_expressed, navi_data$en_expressed)
mcnemar.test(table_lang)
```

```
##
##  McNemar's Chi-squared test with continuity correction
##
## data:  table_lang
## McNemar's chi-squared = 6.6667, df = 1, p-value = 0.009823
```

```
table_role <- table(navi_data$role, navi_data$navi_expressed)
fisher.test(table_role)
```

```
##
##  Fisher's Exact Test for Count Data
##
## data:  table_role
## p-value = 0.2099
## alternative hypothesis: true odds ratio is not equal to 1
## 95 percent confidence interval:
##   0.6519945 32.1453982
## sample estimates:
## odds ratio
##   3.267464
```

Интерпретация теста Макнемара: Полученный p-value меньше порога значимости 0.05, поэтому мы отвергаем нулевую гипотезу (о том, что различий нет) и принимаем альтернативную (аргументы в на'ви действительно опускаются чаще, чем в английских переводах).

Интерпретация теста Фишера: Полученный p-value больше порога значимости, поэтому мы не можем отвергнуть нулевую гипотезу, хоть визуально доля опущений агентов (17%) выше, чем пациентов (6%), статистически эта разница в нашей выборке не является значимой. Она может быть обусловлена случайными факторами или малым объемом данных. Гипотеза 2 не подтверждается на статистически значимом уровне. Мы не можем утверждать, что семантическая роль надежно предсказывает частоту опущения в данном корпусе.

Дискуссия и интерпретация результатов

Проведенный анализ позволил сделать следующие выводы:

1. Подтверждение типологических ожиданий (Гипотеза 1) Статистически значимое различие между На'ви и английским языком объясняется типологической дистанцией между языками. На'ви - это агглютинативный язык, где грамматические отношения кодируются в пределах словоформы с помощью аффиксов, которые позволяют опускать подлежащее без потери смысла. Английский же язык, напротив, является аналитическим языком, и для него критически важно наличие подлежащего, иначе предложение становится неоднозначным.
2. Неожиданный результат по распределению семантических ролей (Гипотеза 2): Вопреки первому предположению о том, что пациенсы опускаются чаще, чем агенсы, визуализация показала обратную ситуацию - агенсы опускаются чаще пациенсов, однако статистически данное различие незначимо.

Возможно, вторая гипотеза не подтвердилась из-за малого размера выборки. Объем датасета может быть недостаточным для выявления устойчивой зависимости при распределении семантических ролей. Дополнительная разметка и увеличение корпуса могли бы изменить результаты и сделать разницу значимой. Помимо этого, значительная часть выборки - это отрывки из диалогов, где говорящий часто опускает агенса (собственное Я), тк субъект речи очевиден из контекста. Пациенс же несет новую информацию, поэтому чаще эксплицируется. Специфика фильма также обязывает уделять внимание внешнему миру Пандоры, планеты на которой живет народ Нави, чтобы показать их тесную связь с природой, поэтому пациенсы добавляются в явном виде, в то время агенсы остаются неизменными и при необходимости легко вычлняются из контекста.

Основными ограничениями в данном исследовании выступает небольшой объем выборки и жанровое однообразие языкового материала.

Предыдущие исследования

Основными источниками литературы о языке На'ви являются Horen Li'fyayä le Na'vi (<https://files.learnnavi.org/docs/horen-lenavi.pdf>), William S. Annis (2024) и naviteri.org (<https://naviteri.org/>), личный блог создателя языка, Пола Фроммера.

Фроммер отмечает, что На'ви - агглютинативный язык с развитой морфологией, где семантические роли явно маркируются суффиксами -l/il (агенс), -t/it (пациенс). В отличие от английского, порядок слов не так важен, поскольку все отношения фиксируются в рамках аффиксов.

До настоящего времени не проводилось количественных исследований на корпусе текстов, которые бы подтвердили частотность опущения аргументов в языке На'ви. Большинство существующих работ носят описательный характер.

Выводы

В ходе исследования была подтверждена первая гипотеза, язык На'ви демонстрирует более высокую частоту опущения аргументов по сранению с английским языком. Влияние семантической роли на частоту опущения в текущей выборке не выявлено как статистически значимое, хотя визуально присутствует тенденция более частого опущения агенсов, что требует дальнейшего изучения на расширенном объеме языкового материала.